Università degli Studi di Bari Aldo Moro

Corso di Ingegneria della Conoscenza (ICon)

# Sistema a Base di Conoscenza per la Valutazione del Rischio da Frana in Campania

*Integrazione di ragionamento logico e apprendimento supervisionato per la mappatura della suscettibilità da frana*

**Componenti del gruppo**

dario gjergo, [725895], gjergo@studenti.uniba.it

Repository GitHub: https://github.com/gjergo/campania-landslide-kbs

A.A. 2024-2025

# Introduzione

Il dissesto idrogeologico rappresenta una delle emergenze ambientali più rilevanti del territorio italiano. La Campania figura tra le regioni con le percentuali più elevate di territorio classificato in classi di pericolosità da frana P3 e P4 (ISPRA, Rapporto 356/2021).

Il presente progetto sviluppa un prototipo di Knowledge-Based System (KBS) per la mappatura della suscettibilità da frana a scala regionale applicato all'intera Campania. Il sistema integra: (1) una base di conoscenza Prolog che codifica regole geomorfologiche esperte derivate dalla letteratura e calibrate sui dati osservati; (2) modelli di apprendimento supervisionato addestrati sull'inventario frane IFFI; (3) un esperimento comparativo che quantifica il contributo della conoscenza esperta rispetto ai soli modelli data-driven.

## Sommario - Argomenti ICon affrontati

- Rappresentazione della conoscenza e ragionamento logico (Prolog, clausole di Horn): KB con fatti e regole che codificano conoscenza geomorfologica esperta su litologia, pendenza, prossimità alla rete idrografica e copertura del suolo. Ogni query attiva una catena di inferenza a quattro livelli con branching condizionale e negazione-as-failure
- Apprendimento supervisionato e classificazione: Regressione Logistica e Random Forest con 5-fold stratified CV su ~6M pixel, valutazione tramite AUC-ROC medio ± deviazione standard
- Integrazione KB+ML (Background Knowledge): esperimento comparativo che verifica se il feature kb_susceptibility — derivato dal ragionamento Prolog — migliora le prestazioni predittive rispetto alla baseline senza conoscenza esperta

# Sezione 1 — Rappresentazione della Conoscenza e Ragionamento Logico

## Sommario

La Knowledge Base (KB) è implementata in Prolog (SWI-Prolog via `pyswip`) e codifica conoscenza geomorfologica esperta sui meccanismi di innesco delle frane in Campania. È composta da **15 fatti e 8 regole** che combinano litologia, pendenza, prossimità alla rete di drenaggio e copertura del suolo per derivare un punteggio di suscettibilità per ciascun pixel (0 = bassa, 1 = media, 2 = alta).

Ogni query attiva una **catena di inferenza a quattro livelli:**

fatti → regole livello 1 → classificazione combinata → encoding numerico

con branching condizionale e negation-as-failure. Il punteggio viene usato come feature aggiuntiva nei modelli ML, realizzando l'integrazione tra ragionamento simbolico e apprendimento statistico.

## Dati Utilizzati

I dati geospaziali sono tutti open data:

| Sorgente | Risoluzione | Utilizzo |
|---|---|---|
| ISPRA IFFI (IdroGEO) | Vettoriale 1:10.000 | Ground truth — poligoni frana (label=1) |
| Copernicus GLO-30 DEM (ESA) | 30 m | slope, aspect, TWI, curvature, flow accumulation |
| Carta Geologica 1:100.000 (ISPRA SGI) | Vettoriale 1:100.000 | Classi litologiche — 5 classi geotecniche |
| CORINE Land Cover 2018 (Copernicus) | 100 m → 30 m | Copertura del suolo (input KB + feature ML) |
| OpenStreetMap / Geofabrik | Vettoriale | Distanza rete viaria (log-trasformata) |
| Rete drenaggio (da DEM) | 30 m derivata | Distanza rete idrografica |

## Decisioni di Progetto nella Pipeline

### Classificazione litologica

La Carta Geologica 1:100.000 contiene 433 nomi di unità distinti su 19.286 poligoni: la stessa formazione riceve denominazioni diverse nei diversi fogli cartografici (artefatti da bordo foglio). Per rendere il dato utilizzabile dalla KB si è proceduto ad aggregare le unità in **5 classi geotecniche** omogenee per meccanismo di cedimento (Catani et al., 2013), tramite classificazione keyword-based con ordine di

priorità. Il risultato copre il 97% dei poligoni; un filtro di maggioranza 3×3 pixel attenua gli artefatti residui sul raster.

| Classe | Cod. | Descrizione | Suscettibilità intrinseca |
|---|---|---|---|
| `unconsolidated_weak` | 1 | Depositi versante, alluvioni, suoli residuali | Molto alta |
| `volcanic_pyroclastic` | 2 | Tufi, ignimbriti, lave, piroclastiti | Alta |
| `flysch_clastic` | 3 | Argille, marne, arenarie, flysch | Alta |
| `competent_clastic` | 4 | Conglomerati, brecce cementate | Media |
| `hard_rock` | 5 | Calcari, dolomie | Bassa |

### Derivazione morfometrica e rete di drenaggio

Slope e aspect sono calcolati con `pysheds` sul DEM in EPSG:32633 (UTM 33N). TWI = ln(flow_accumulation / tan(slope)); curvature calcolate con `scipy.ndimage`. La rete di drenaggio è estratta dal DEM con soglia flow_accumulation > 1000 celle upstream (~0,9 km²). La distanza euclidea è calcolata con `scipy.ndimage.distance_transform_edt`; la distanza da strade OSM è log-trasformata — log(1 + dist_m) — per attenuare l'effetto a grandi distanze.

### Motivazione della struttura combinata delle regole

L'analisi esplorativa ha rivelato un apparente paradosso: il tasso grezzo di frana per classe litologica mostrava `volcanic_pyroclastic` con solo il 3% di pixel in frana (il più basso), mentre `flysch_clastic` raggiungeva il 30%. La spiegazione risiede nella distribuzione topografica: i pixel vulcanici in Campania sono concentrati nella piana dei Campi Flegrei (pendenza media 6,1°), dove il cedimento di versante è impossibile a prescindere dalla litologia. Il modello corretto non è quindi *litologia → suscettibilità* ma **litologia × pendenza → suscettibilità**, il che giustifica la struttura combinata delle regole Prolog descritta nel seguito.

## Struttura della Knowledge Base

La KB è nel file `src/kb/landslide_kb.pl`, caricata a runtime via `prolog.consult()` con path assoluto.

### Fatti (15)

I fatti codificano la conoscenza di dominio sotto forma di clausole atomiche (clausole definite con corpo vuoto):

```
% Soglie pendenza per litologia (mediana IFFI, derivate
empiricamente)
critical_slope(hard_rock, 18.0).
```

```
critical_slope(competent_clastic, 11.0).
critical_slope(flysch_clastic, 10.0).
critical_slope(unconsolidated_weak, 9.0).
critical_slope(volcanic_pyroclastic, 9.0).
critical_slope(unknown, 10.0).

% Classi geotecnicamente deboli (Catani et al., 2013)
weak_material(unconsolidated_weak).
weak_material(volcanic_pyroclastic).
weak_material(flysch_clastic).

% Soglia prossimità drenaggio in metri (Corominas et al.,
2014)
drainage_risk_threshold(200.0).

% Copertura stabilizzante/destabilizzante (Löbmann et  al.,
2020)
stabilizing_cover(311).  stabilizing_cover(312).
stabilizing_cover(313).
destabilizing_cover(331). destabilizing_cover(332).
destabilizing_cover(333). destabilizing_cover(334).
```

### Regole livello 1: condizioni atomiche (5 regole)

Ciascuna regola è una clausola definita della forma $h \leftarrow a_1 \wedge \ldots \wedge a_m$ che verifica una singola condizione predisponente:

```
slope_susceptible(L, S)    :- critical_slope(L, T), S > T.
material_susceptible(L, S) :- weak_material(L), S > 5.0.
drainage_susceptible(L, D) :- weak_material(L),
drainage_risk_threshold(T), D < T.
cover_destabilized(C)      :- destabilizing_cover(C).
cover_stabilized(C)        :- stabilizing_cover(C).
```

### Regole livello 2: classificazione combinata (6 regole, di cui 3 clausole di Horn)

Questo livello implementa il cuore del ragionamento. Le regole assegnano la classe di suscettibilità combinando le condizioni atomiche del livello 1. L'ordine delle clausole è significativo: Prolog tenta la risoluzione SLD dall'alto verso il basso, per cui le regole per `high` precedono quelle per `medium`, che a loro volta precedono il fallback `low`.

```
% HIGH: pendenza critica + materiale debole
kb_susceptibility(L, S, _, _, high) :-
     slope_susceptible(L, S), weak_material(L).

% HIGH: pendenza critica + prossimità drenaggio  (materiale
debole)
kb_susceptibility(L, S, D, _, high) :-
     slope_susceptible(L, S), drainage_susceptible(L, D).
```

```
% HIGH: pendenza critica + copertura destabilizzante
(materiale NON debole)
kb_susceptibility(L, S, _, C, high) :-
     slope_susceptible(L, S), cover_destabilized(C), \+
weak_material(L).

% MEDIUM: pendenza critica ma nessuna condizione aggravante
(materiale NON debole)
kb_susceptibility(L, S, _, C, medium) :-
     slope_susceptible(L, S), \+ weak_material(L), \+
cover_destabilized(C).

% MEDIUM: materiale debole su pendenza bassa (> 5° ma  sotto
soglia critica)
kb_susceptibility(L, S, _, _, medium) :-
  material_susceptible(L, S), \+ slope_susceptible(L, S).

% LOW: fallback — nessuna condizione attivata
kb_susceptibility(_, _, _, _, low).
```

Le tre clausole che usano `\+` (negation-as-failure, NAF) sono **clausole di Horn**: la NAF corrisponde a verificare che un certo atomo non sia dimostrabile dalla KB, trasformando la clausola definita in un vincolo implicito. Come trattato nella teoria (§4.7 delle dispense), la NAF implementa l'assunzione di mondo chiuso (CWA): se `weak_material(L)` non è dimostrabile per un dato `L`, si conclude che il materiale non è debole. La KB è **aciclica**, il che garantisce che il completamento di Clark sia consistente e che la NAF termini sempre.

Regole livello 3: encoding numerico (3 regole)

```
susceptibility_score(L, S, D, C, 2) :-
kb_susceptibility(L, S, D, C, high).

susceptibility_score(L, S, D, C, 1) :-
kb_susceptibility(L, S, D, C, medium).

susceptibility_score(_, _, _, _, 0).
```

Queste regole traducono l'output simbolico (`high`, `medium`, `low`) in un valore numerico utilizzabile come feature dai modelli ML.

## Catena di Inferenza

Ogni query `susceptibility_score(L, S, D, C, Score)` attiva una dimostrazione **top-down** (risoluzione SLD) su quattro livelli:

1. **Fatti**: il motore Prolog unifica i parametri con i fatti (`critical_slope/2`, `weak_material/1`, ecc.)

2. **Regole livello 1**: verifica delle condizioni atomiche (confronti numerici e lookup)
3. **Regole livello 2**: classificazione combinata con branching condizionale; la NAF (\+) innesca sotto-dimostrazioni che possono avere successo o fallire
4. **Regole livello 3**: mapping simbolico → numerico

Il risultato è **output derivato**: il punteggio numerico non è mai esplicitamente memorizzato nella KB ma viene calcolato per ogni query attraverso la catena inferenziale. Questo corrisponde alla relazione KB ⊢ g della teoria della dimostrazione: dato un pixel con attributi (L, S, D, C), il sistema dimostra quale score ne segue logicamente.

## Scelte Progettuali

### Soglie di pendenza critica

Le soglie sono derivate empiricamente dalla **mediana della pendenza dei pixel IFFI** (inventario frane) per ciascuna classe litologica, approccio analogo a Catani et al. (2013). Sono impostate leggermente sotto la mediana per catturare condizioni necessarie non sufficienti:

| Classe | Mediana IFFI (°) | Soglia KB (°) | Margine |
|---|---|---|---|
| `hard_rock` | 19,6 | 18,0 | −1,6 |
| `competent_clastic` | 12,0 | 11,0 | −1,0 |
| `flysch_clastic` | 10,6 | 10,0 | −0,6 |
| `unconsolidated_weak` | 9,9 | 9,0 | −0,9 |
| `volcanic_pyroclastic` | 9,9 | 9,0 | −0,9 |

Soglia di drenaggio (200 m)

Motivata da Corominas et al. (2014): lo scalzamento al piede da parte dei corsi d'acqua è un meccanismo predisponente primario per le classi di materiale debole.

### Classi CORINE stabilizzanti/destabilizzanti

Motivate da Löbmann et al. (2020): la copertura forestale (codici 311–313) aumenta la coesione del suolo tramite ancoraggio radicale; le superfici nude, scarsamente vegetate o bruciate (codici 331–334) sono destabilizzanti per assenza di questo effetto. Queste classi intervengono nella KB solo come fattore aggravante o neutro, non come condizione sufficiente di per sé.

### Ottimizzazione per efficienza

L'area di studio comprende circa 6 milioni di pixel. Per evitare 6M query Prolog singole, l'inferenza opera sulle **combinazioni uniche** di (litho_class, bin_slope_0.5°, bin_dist_drain_50m, corine_code), riducendo le query da ~6M a ~24.000. Questa ottimizzazione è possibile perché la KB è **deterministica**: stessi input producono sempre lo stesso output, proprietà garantita dalla struttura a clausole definite con NAF aciclica.

## Valutazione della KB

### Come classificatore autonomo

La KB viene valutata come classificatore binario con soglia score ≥ 1 → positivo:

| Precision | Recall | F1 | AUC-ROC |
|---|---|---|---|
| 0,232 | 0,874 | 0,367 | 0,677 |

L'elevato recall (0,874) con bassa precision (0,232) è il **pattern atteso per condizioni necessarie non sufficienti**: la KB identifica quasi tutti i pixel di frana reali ma include anche versanti predisposti che non hanno ancora ceduto. In contesto di risk assessment questa asimmetria è desiderabile, poiché un falso negativo (area pericolosa non identificata) è più grave di un falso positivo.

### Distribuzione del punteggio per classe

| Score | Condizione logica attivata | Pixel frana | Background |
|---|---|---|---|
| 2 — alta | `slope_susc ∧ (weak ∨ near_drain ∨ bare_cover)` | 46,3% | 24,1% |
| 1 — media | `slope_susc ∨ material_susc` (senza condizioni per high) | 41,1% | 33,8% |
| 0 — bassa | Nessuna condizione attivata | 12,6% | 42,1% |

La distribuzione conferma il potere discriminante della KB: il 46,3% dei pixel in frana ottiene score 2 (vs. 24,1% nel background), mentre solo il 12,6% finisce a score 0 (vs. 42,1%). Il punteggio KB cattura quindi informazione complementare rispetto alle sole feature numeriche, giustificandone l'integrazione nei modelli ML.

Analisi della complessità

La KB ha una struttura a clausole definite estese con NAF, il che la colloca nel frammento delle **clausole di Horn**. La dimostrazione per ciascuna query ha complessità limitata:

- **Profondità massima della catena inferenziale**: 4 livelli (score → susceptibility → condizione atomica → fatto), quindi costante rispetto alla dimensione dell'area di studio.
- **Branching**: al livello 2 ci sono 6 clausole alternative per `kb_susceptibility`, ma Prolog le tenta in ordine e si arresta alla prima che ha successo (cut implicito per la semantica dell'applicazione). Nel caso peggiore si tentano tutte e 6 le clausole.

- **NAF**: ciascuna invocazione di \+ richiede al più una sotto-dimostrazione di profondità 1 (verifica di un fatto), quindi non introduce rischi di cicli o divergenza.
- **Complessità totale per query**: O(1), poiché il numero di fatti e regole è fisso e piccolo (23 clausole).

## Strumenti Utilizzati

- **SWI-Prolog / pyswip**: motore inferenziale Prolog invocato da Python
- **geopandas, rasterio, shapely**: processing GIS e rasterizzazione vettoriale
- **pysheds, scipy.ndimage**: parametri morfometrici e calcolo distanze euclidee

# Sezione 2 — Apprendimento Supervisionato e Classificazione

## Sommario

Due classificatori supervisionati — Regressione Logistica (LR) e Random Forest (RF) — vengono addestrati sul feature matrix derivato dalla pipeline geospaziale. L'esperimento principale confronta le prestazioni con e senza il feature `kb_susceptibility` per quantificare il contributo della conoscenza esperta codificata nella KB Prolog. La valutazione usa 5-fold stratified cross-validation con AUC-ROC come metrica principale, riportando media e deviazione standard.

## Costruzione del Feature Matrix

Il feature matrix campiona i pixel validi di Campania a 30 m (15.033.189 pixel nel dominio valido). Tutti i pixel positivi (label=1, dentro poligoni IFFI) sono inclusi integralmente. I negativi sono campionati con rapporto 5:1 (neg:pos), stratificato per `litho_class`. La stratificazione è necessaria: senza di essa `flysch_clastic` (27% dell'area) verrebbe sovracampionato a scapito di `volcanic_pyroclastic` (15%) e `hard_rock` (18%). Campionamento con `numpy.random.default_rng(seed=42)`.

| Parametro | Valore | Motivazione |
|---|---|---|
| Pixel totali Campania | 15.033.189 | Dominio di studio a 30m |
| Positivi (IFFI) | 999.696 | Tutti i pixel in poligoni frana validi |
| Negativi campionati | 4.998.480 | 5:1 stratificato per litho_class |
| Totale | 5.998.176 righe | 11 feature + label + metadati spaziali |
| Seed RNG | 42 | Riproducibilità |

Ogni pixel è assegnato a uno dei 25 blocchi di una griglia 5×5 sull'extent di Campania. Questi blocchi non vengono usati per la CV (si usa stratified k-fold standard). Limitazione documentata: la CV spaziale per blocchi eviterebbe l'autocorrelazione spaziale tra pixel adiacenti in fold diversi, ed è raccomandata per future estensioni.

Le 11 feature utilizzate sono: `slope`, `aspect`, `profile_curvature`, `planform_curvature`, `twi`, `flow_accumulation` (derivate dal DEM), `litho_class` (0–5), `corine` (codice CLC), `dist_drainage` (metri), `dist_roads` (log-trasformata), `kb_susceptibility` (0–2, derivato dalla KB Prolog).

## Scelta dei Modelli e degli Iperparametri

I due modelli sono stati scelti per rappresentare due classi di complessità differenti, con l'obiettivo specifico di testare l'effetto della Background Knowledge su modelli con capacità di apprendimento diverse.

**Regressione Logistica**: `max_iter=1000`, `C=1.0` (default), regolarizzazione L2. `StandardScaler` applicato dentro il loop di CV (fit solo sul train fold per evitare data leakage). LR è un modello lineare: non può apprendere interazioni tra feature senza trasformazioni esplicite dei dati in input. Questo rende particolarmente informativo il test con/senza `kb_susceptibility`, poiché la KB precomputa esattamente le interazioni non-lineari (litologia×pendenza×drenaggio×copertura) che LR non è in grado di scoprire autonomamente.

**Random Forest**: `n_estimators=100`, `random_state=42`, `n_jobs=-1`, profondità illimitata. Non è stato effettuato tuning degli iperparametri (ad es. tramite GridSearchCV): l'obiettivo dell'esperimento non è ottimizzare le prestazioni assolute, ma confrontare la condizione con/senza KB feature a parità di configurazione. RF, essendo un ensemble di alberi decisionali, può apprendere autonomamente interazioni non-lineari tra feature attraverso i criteri di split.

**Metrica principale — AUC-ROC**: il dataset rimane sbilanciato (1:5) anche dopo il campionamento; accuracy e F1 al threshold 0,5 sarebbero fuorvianti. AUC misura la capacità discriminante indipendentemente dalla soglia di decisione ed è la metrica standard nella letteratura sulla suscettibilità da frana (Catani et al., 2013; Guzzetti et al., 2006).

## Protocollo di Valutazione

La valutazione segue il protocollo della K-Fold Cross Validation con K=5 fold stratificati per classe. Ad ogni iterazione, 4 fold sono usati per il training e 1 per il test, ruotando fino a coprire l'intero dataset. Per ogni modello si riportano media e deviazione standard delle metriche sui 5 fold.

L'esperimento viene eseguito in quattro configurazioni: LR senza KB, LR con KB, RF senza KB, RF con KB. Le configurazioni differiscono solo per la presenza o assenza del feature `kb_susceptibility` nel set di input.

## Risultati

Risultati della 5-fold stratified cross-validation (media ± deviazione standard):

| Modello / Feature set | AUC-ROC | F1 | Precision | Recall |
|---|---|---|---|---|
| KB standalone (baseline) | 0,677 ± — | 0,367 | 0,232 | 0,874 |
| LR senza KB | 0,599 ± 0,0004 | 0,001 ± 0,0001 | 0,107 ± 0,011 | 0,001 ± 0,0001 |
| LR con KB | 0,738 ± 0,0001 | 0,038 ± 0,0008 | 0,443 ± 0,005 | 0,020 ± 0,0004 |
| RF senza KB | 0,854 ± 0,0004 | 0,357 ± 0,0014 | 0,603 ± 0,001 | 0,254 ± 0,0014 |
| RF con KB | 0,852 ± 0,0003 | 0,351 ± 0,0017 | 0,598 ± 0,001 | 0,248 ± 0,0016 |

Le deviazioni standard sono molto basse (ordine di $10^{-4}$) a causa della dimensione del dataset (~6M righe): con fold di oltre un milione di pixel ciascuno, le stime sono estremamente stabili tra un fold e l'altro.

## Analisi dei Risultati

Il risultato principale riguarda l'interazione tra Background Knowledge e capacità del modello base.

**Effetto sulla Regressione Logistica (+0,139 AUC)**: l'aggiunta di `kb_susceptibility` produce un incremento da 0,599 a 0,738 in AUC. Questo è coerente con la natura del feature: la KB precomputa la combinazione non-lineare litologia×pendenza×drenaggio×copertura in un singolo feature discreto (0, 1 o 2) che LR può sfruttare linearmente. Senza questo feature, LR ha accesso ai singoli input (slope, litho_class, ecc.) ma non può scoprire le loro interazioni. Il recall molto basso di LR (0,001 senza KB, 0,020 con KB) al threshold di 0,5 riflette un problema di calibrazione tipico dei modelli lineari su dataset sbilanciati: l'AUC conferma che il potere discriminante esiste ma richiede un tuning della soglia per uso pratico.

**Effetto sul Random Forest (−0,002 AUC, trascurabile)**: RF con KB ottiene 0,852 vs RF senza KB 0,854, differenza ampiamente entro una deviazione standard. La feature importance conferma il motivo: `kb_susceptibility` riceve solo il 3,7% di importanza (ultima posizione), poiché RF ha accesso diretto a `slope` (14,2%), `litho_class` (6,3%) e `corine` (4,3%) — gli stessi input grezzi che la KB combina. RF impara autonomamente le interazioni che la KB codifica esplicitamente.

La KB risulta quindi sostanzialmente utile per modelli lineari tuttavia ridondante per modelli non-lineari, risultato coerente con la letteratura sull'integrazione di

Background Knowledge nei sistemi ML e costituisce il principale risultato dell'esperimento comparativo.

Feature importance Random Forest (fit su dataset completo):

| Feature | Importanza | Nota |
|---|---|---|
| slope | 0,142 | Fattore primario |
| planform_curvature | 0,120 | Convergenza flusso superficiale |
| aspect | 0,116 | Orientamento versante |
| twi | 0,113 | Indice umidità topografica |
| profile_curvature | 0,112 | Accelerazione flusso |
| dist_roads | 0,108 | Effetto infrastrutture |
| dist_drainage | 0,099 | Scalzamento al piede |
| litho_class | 0,063 | Litologia geotecnica |
| flow_accumulation | 0,048 | Rete idrografica implicita |
| corine | 0,043 | Copertura suolo |
| kb_susceptibility | 0,037 | Conoscenza esperta (ridondante per RF) |

## Strumenti Utilizzati

- **scikit-learn**: `LogisticRegression`, `RandomForestClassifier`, `StratifiedKFold`, `StandardScaler`, `roc_auc_score`
- **pandas, numpy, pyarrow**: feature matrix in formato parquet (215,9 MB)

## Conclusioni

Il progetto ha sviluppato un Knowledge-Based System che integra ragionamento logico simbolico e apprendimento supervisionato per la mappatura della suscettibilità da frana in Campania. I due aspetti principali del sistema — la KB Prolog e i classificatori ML — sono stati valutati sia autonomamente sia in combinazione.

Il risultato principale dell'esperimento comparativo riguarda l'interazione tra Background Knowledge e capacità del modello. Il feature `kb_susceptibility` migliora la Regressione Logistica di +0,139 AUC (da 0,599 a 0,738), poiché precomputa le interazioni non-lineari che un modello lineare non può scoprire autonomamente. Per il Random Forest l'effetto è trascurabile (−0,002 AUC), confermato dalla feature importance che colloca `kb_susceptibility` all'ultima posizione (3,7%): RF apprende autonomamente le stesse interazioni che la KB codifica esplicitamente.

Il sistema presenta alcune limitazioni. L'uso di k-fold stratificata standard anziché CV spaziale può portare a una sovrastima delle prestazioni per autocorrelazione tra pixel adiacenti assegnati a fold diversi. Un primo tentativo con i dati pluviometrici ERA5 si sono rivelati inutilizzabili per la risoluzione insufficiente (9 km vs 30 m del DEM). Gli artefatti da bordo foglio nella Carta Geologica 1:100.000 sono stati parzialmente mitigati dall'aggregazione in 5 classi geotecniche e dal filtro di maggioranza 3×3, ma non completamente eliminati.

Tra gli sviluppi futuri: l'adozione di spatial block CV per una valutazione più rigorosa; l'integrazione di dati pluviometrici ARPAC ad alta risoluzione; l'estensione verso modelli di hazard dinamico con soglie di innesco pluviometriche (Guzzetti et al., 2007); la validazione esterna tramite confronto con la mosaicatura ISPRA P1–P4.

## Riferimenti Bibliografici


[1] Catani, F., Lagomarsino, D., Segoni, S., Tofani, V. (2013). Landslide susceptibility estimation by random forests technique. Natural Hazards and Earth System Sciences, 13, 2815–2831. https://doi.org/10.5194/nhess-13-2815-2013

[2] Corominas, J., et al. (2014). Recommendations for the quantitative analysis of landslide risk. Bulletin of Engineering Geology and the Environment, 73(2), 209–263. https://doi.org/10.1007/s10064-013-0538-8

[3] Löbmann, M.T., Geitner, C., Wellstein, C., Zerbe, S. (2020). The influence of herbaceous vegetation on slope stability — a review. Earth-Science Reviews, 209, 103328. https://doi.org/10.1016/j.earscirev.2020.103328

[4] Alvioli, M., et al. (2020). Landslide susceptibility assessment in complex geological settings: sensitivity to geological information. Landslides, 17, 97–112. https://doi.org/10.1007/s10346-019-01340-2

[5] Trigila, A., Iadanza, C., et al. (2021). Dissesto idrogeologico in Italia: pericolosità e indicatori di rischio. ISPRA Rapporti 356/2021.

[6] Tufano, R., et al. (2023). A revised landslide inventory of the Campania region (Italy). Scientific Data, 10, 353. https://doi.org/10.1038/s41597-023-02155-6

[7] Guzzetti, F., et al. (2006). Estimating the quality of landslide susceptibility models. Geomorphology, 81(1–2), 166–184. https://doi.org/10.1016/j.geomorph.2006.03.036

[8] Guzzetti, F., et al. (2007). Rainfall thresholds for the initiation of landslides in central and southern Italy. Meteorology and Atmospheric Physics, 98, 239–267. https://doi.org/10.1007/s00703-007-0262-7

[9] Iadanza, C., Trigila, A., et al. (2021). IdroGEO: a collaborative web mapping application. ISPRS Int. J. Geo-Inf., 10(2), 89. https://doi.org/10.3390/ijgi10020089